



清华大学  
Tsinghua University

# 第三单元 第三讲

## 高速缓冲存储器Cache

刘卫东

计算机科学与技术系

# 内容提要



## Cache的地址映射

- 直接映射
- 全相联映射
- 多路组相联

## Cache写策略

## 提高Cache性能的途径

- 组织结构
- Cache参数（大小、块大小、替换策略）

# 高速缓冲存储器Cache



- ❖ 基于程序的局部性原理
  - ❖ 时间局部性
  - ❖ 空间局部性
- ❖ 利用静态存储器的高速特性
- ❖ 设置于主存储器与CPU之间
- ❖ 缓存CPU频繁访问的信息
- ❖ 提高CPU访问存储器的整体性能

# 层次存储器系统



- ✚ 使用高速缓冲存储器Cache来提高CPU对存储器的平均访问速度。
- ✚ 时间局部性：最近被访问的信息很可能还要被访问。
  - ▣ 将最近被访问的信息项装入到Cache中。
- ✚ 空间局部性：最近被访问的信息临近的信息也可能被访问。
  - ▣ 将最近被访问的信息项临近的信息一起装入到Cache中。

# 需要解决的问题



❁ 如何通过主存地址去访问Cache?

❁ 全相联

❁ 直接映射

❁ 多路组相联

❁ 如何保证层次间一致性?

❁ 有效位、写策略

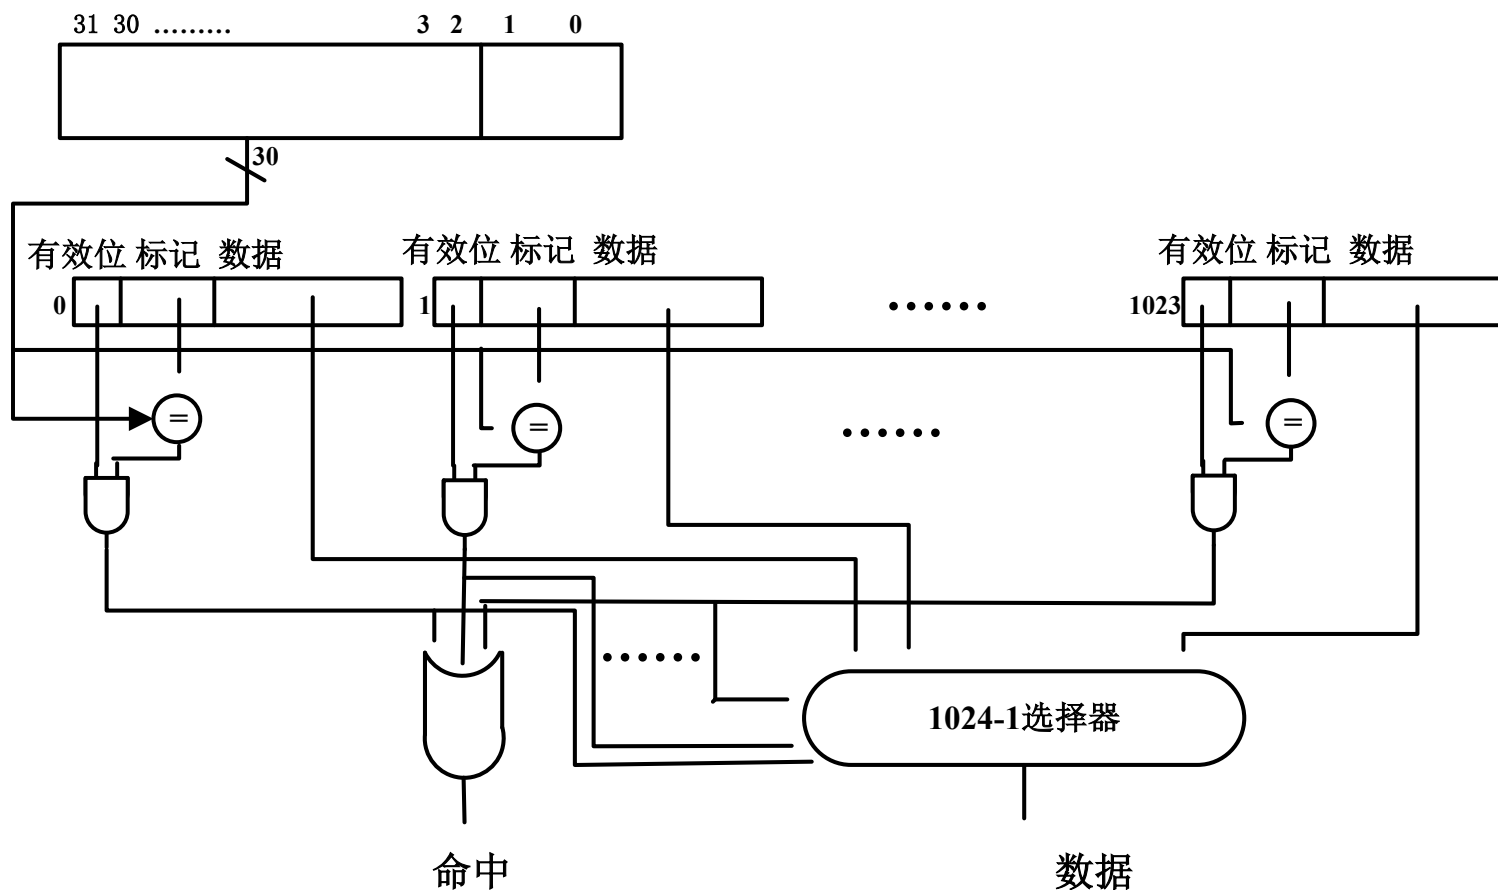
❁ 如何进一步提高Cache性能?

❁ Cache的组织：块大小


❁ 替换策略

❁ 接入方式


# 全相联映射硬件实现



# 直接映射 Cache硬件实现



# 两路组相联方式







# 两路组相联方式

## 特点

1. 前两种方式的综合方案。先通过直接映射方法确定组，再在组内通过全相联方式确定行。
2. 集中了两个方式的优点。成本也不太高。

是常用的方式

# 组相联Cache访问举例



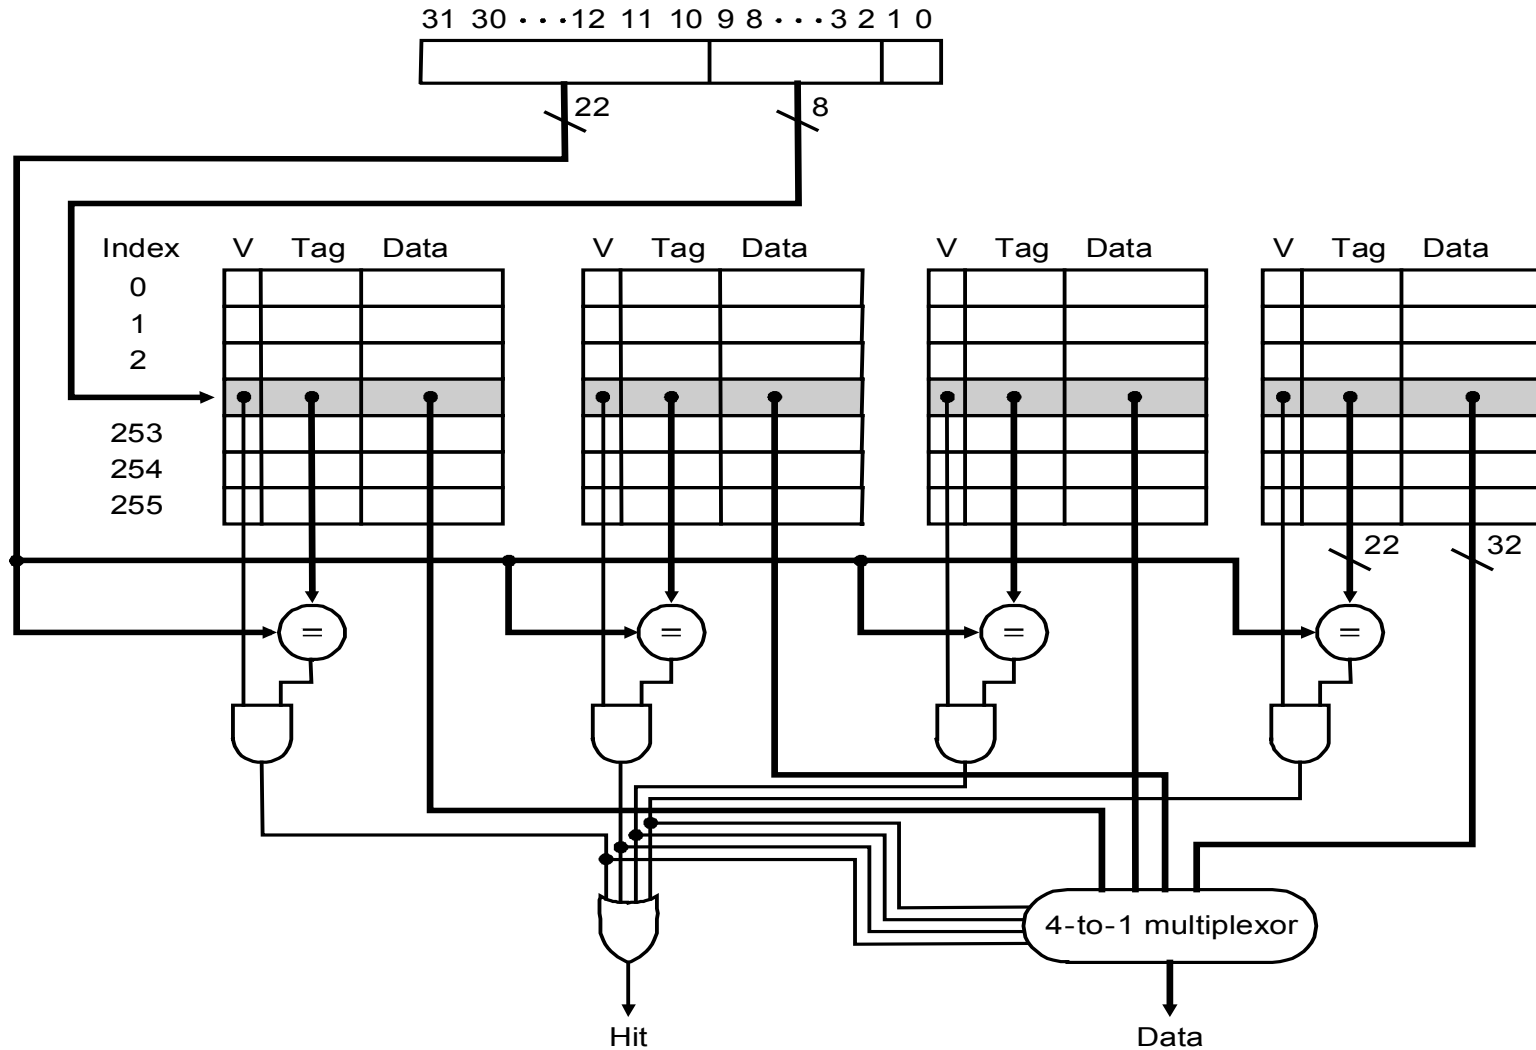
⌘ 假设有下列访问主存顺序：

- ☒ Read location 0: Miss
- ☒ Read location 16: Miss
- ☒ Read location 32: Miss
- ☒ Read location 4: Hit
- ☒ Read location 8: Hit
- ☒ Read location 36: Hit
- ☒ Read location 32: Hit
- ☒ Read location 128: Miss
- ☒ Read location 148: Miss
- ☒ Read location 0: Hit
- ☒ Read location 128: Hit
- ☒ Read location 4: Hit
- ☒ Read location 132: Hit

0-15  
64-79  
...

0-15	128-143
16-31	144-159
32-47	

# 四路组相联Cache实现



主存：4GB，Cache：4KB 块大小：4B，4路组相联，索引？标志？

# 直接映射到全相联



One-way set associative  
(direct mapped)

Block	Tag	Data
0		
1		
2		
3		
4		
5		
6		
7		

Two-way set associative

Set	Tag	Data	Tag	Data
0				
1				
2				
3				

Four-way set associative

Set	Tag	Data	Tag	Data	Tag	Data	Tag	Data
0								
1								

Eight-way set associative (fully associative)

Tag	Data	Tag	Data	Tag	Data	Tag	Data	Tag	Data	Tag	Data	Tag	Data	Tag	Data



# 一致性保证

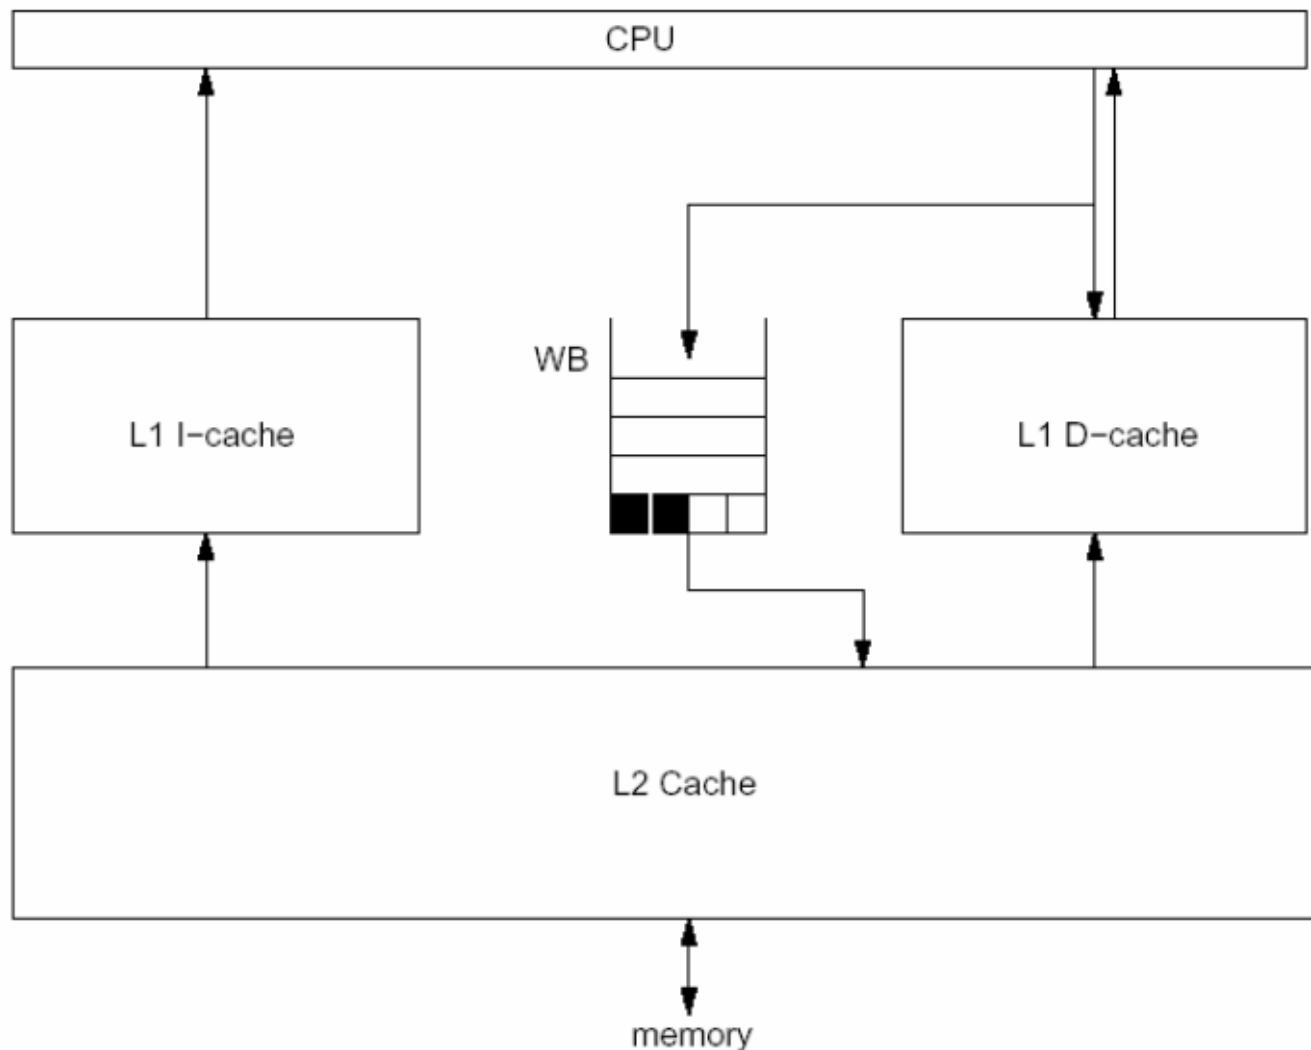
## ✚ 写直达 (Write through)

- ✚ 强一致性保证，效率低
- ✚ 在Cache中命中
  - ◆ 同时修改Cache和对应的主存内容
- ✚ 没有在Cache中命中
  - ◆ 写分配 (Write allocate)
  - ◆ 非写分配 (not Write allocate)

## ✚ 拖后写 (Write back)

- ✚ 弱一致性保证，替换时再写主存
  - ◆ 主动替换
  - ◆ 被动替换
- ✚ 通过监听总线上的访问操作来实现
- ✚ 实现复杂，效率比较高

# Cache写（命中）



# Cache（不命中）写策略



Steps	Write through				Write back	
	Write allocate		No write allocate		Write allocate	
	fetch on miss	no fetch on miss	<u>write around</u>	write invalidate <b>Hit</b>	<u>fetch on miss</u>	no fetch on miss
1	pick replacement	pick replacement			pick re-placement	pick re-placement
2				invalidate tag	[write back]	[write back]
3	fetch block				fetch block	
4	write cache	write partial cache			write cache	write partial cache
5	write memory	write memory	write memory	write memory		

# 提高存储访问的性能



平均访问时间 =

命中时间  $\times$  命中率 + 失效损失  $\times$  缺失率

- ✚ 提高命中率
- ✚ 缩短缺失时的访问时间
- ✚ 提高Cache本身的速度





# Cache缺失的四类原因

## 必然缺失 (Compulsory Miss)

- ❑ 开机或者是进程切换
- ❑ 首次访问数据块

## 容量缺失 (Capacity Miss)

- ❑ 活动数据集超出了Cache的大小

## 冲突缺失 (Conflict Miss)

- ❑ 多个内存块映射到同一Cache块
- ❑ 某一Cache组块已满，但空闲的Cache块在其他组

## 无效缺失

- ❑ 其他进程修改了主存数据

# 对策



## 必然缺失

- ❑ 世事总有缺憾
- ❑ 如果程序访问存储器的次数足够多，也就可以忽略了
- ❑ 策略
  - ◆ 预取

## 容量缺失

- ❑ 出现在Cache容量太小的时候
- ❑ 增加Cache容量，可缓解缺失现象


## 冲突缺失

- ❑ 两块不同的内存块映射到相同的Cache块
- ❑ 对直接映射的Cache，这个问题尤其突出
  - ◆ 增加Cache容量有助于缓解冲突
  - ◆ 增加相联的组数有助于缓解冲突

# 影响Cache缺失率的因素



- 经验总结：容量为 $N$ 、采用直接映射方式Cache的缺失率和容量为 $N/2$ 、采用2路组相联映射方式Cache的缺失率相当



# 影响命中率的因素



## Cache 容量

- 大容量可以提高命中率，但是.....

## Cache块大小

- 选择多大的行，还真是个问题

## 地址映射方式

- 多路组相联，但到底多少路呢？


## 替换算法

- 替换哪块出去呢？


## 多级Cache

- 给用户更多的选择

# 命中率与容量的关系



# 块大小和缺失率的关系





# 块大小的权衡

❊ 数据块较大可以更好地利用空间局部性：

❑ 数据块大意味着缺失损失的增大：


◆ 需要花费更长的时间来装入数据块

❑ 若块大小相对Cache总容量来说太大的话，命中率将降低


◆ Cache块数太少

❊ 平均访问时间 = 命中时间 x 命中率 + 失效损失 x 缺失率


缺失损失



缺失率



平均访问时间



## ❖ 直接映射

- ❑ 主存中的一块只能映射到Cache中唯一的一个位置
- ❑ 定位时，不需要选择，只需替换

## ❖ 全相联映射

- ❑ 主存中的一块可以映射到Cache中任何一个位置

## ❖ N路组相联映射

- ❑ 主存中的一块可以选择映射到Cache中N个位置

## ❖ 全相联映射和N路组相联映射的失效处理

- ❑ 从主存中取出新块
- ❑ 为了腾出Cache空间，需要替换出一个Cache块
- ❑ 不唯一，则需要选择应替出哪块



# 块替换策略



## 最近最少使用LRU

- ❑ 满足程序局部性要求
- ❑ 有较高命中率
- ❑ 硬件实现复杂

## 先进先出FIFO

- ❑ 满足时间局部性
- ❑ 实现比较简单

## 随机替换RAND

- ❑ 实现简单
- ❑ 命中率也不太低

# 多级Cache




- ❖ 采用两级或更多级cache来提高命中率
  - ❖ 增加Cache层次
  - ❖ 增加了用户的选择
- ❖ 将Cache分解为指令Cache和数据Cache
  - ❖ 指令流水的现实要求
  - ❖ 根据具体情况，选用不同的组织方式、容量

# 多级Cache



Options: *separate* data and instruction caches, or a *unified* cache




Inclusive vs. Exclusive

- ✚ 在处理器中设置独立的数据Cache和指令Cache
- ✚ 在处理器外设置第二级Cache，甚至是第三级Cache


# CACHE 接入系统的体系结构



1. 侧接法：像入出设备似的连接到总线上，优点是结构简单，成本低，缺点是不利于降低总线占用率。



2. 隔断法：把原来的总线打断为两段，使 CACHE 处在两段之间，优点是有利于提高总线利用率，支持总线并发操作，缺点是结构复杂，成本较高。



# Pentium上的Cache



- ❖ Intel的80386及更早的处理器芯片上并没有片上的高速缓冲存储器。
- ❖ 80486: 引入一个8K字节的片上Cache, 其块大小为16字节, 采用的是四路组相联映射方式。
- ❖ Pentium: 芯片上已经有了两个8K字节的片上cache, 一个用作指令缓存, 另一个用作数据缓存。它们的块大小都为32字节, 采用两路组相联的组织方式。

# Pentium的数据缓存



- ❖ 数据缓存由128组，每组两个cache块组成，从逻辑上可以看成是大小为4K字节的两“路”。
- ❖ 每个cache块都有20位的标记位和两位的状态位与其对应，标记位即存放在该cache块中的主存块的地址的高20位，两位状态位可以标记出4个不同的块状态。
- ❖ 替换算法采用的是最近最少使用法（LRU），所以对每组cache块还需要有1位的LRU位来表示CPU最近访问的是该组中的哪一块。
- ❖ 采用拖后写策略。
- ❖ 支持两级Cache。

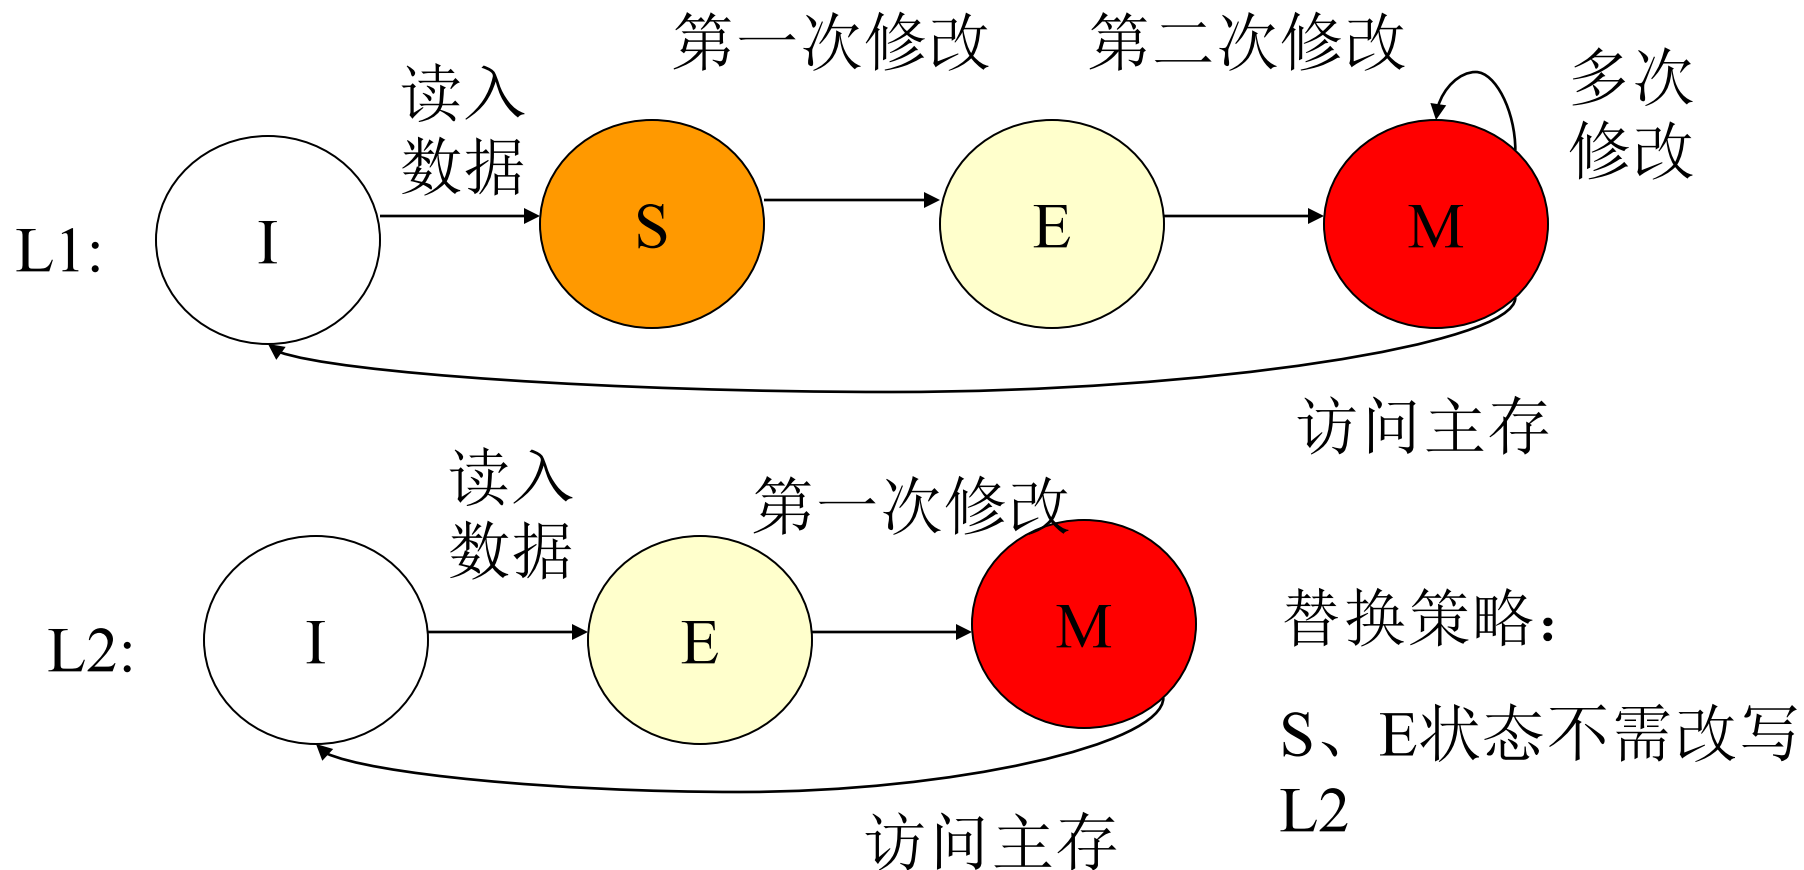
# 一致性保证策略(MESI)



- ❖ 修改态 (M) : 处于这个状态的cache块中的数据已经被修改过, 和主存中对应的数据已不同, 只能从cache中读到正确的数据。
- ❖ 独占态 (E) : 处于本状态的cache块的数据和主存中对应的数据块内容相同, 而且在其它cache中没有副本。
- ❖ 共享态 (S) : 处于本状态的cache块的数据和主存中对应的数据块内容相同, 而且可能在其它cache中有该块的副本。
- ❖ 无效态 (I) : 处于本状态的cache块中尚未装入数据。



# 两级Cache块的状态转换



# 写主存顺序



- ✚ L2监听到其它总线主设备读请求，并要求该设备等待；
- ✚ L2将要被写的地址传给L1，如果L1中的数据在一次写之后有了新的修改（状态为M），则需要将L1中该块的数据写回到主存中。任何情况下，都将该块的状态标记为非法态（I）。
- ✚ 如果L1中的数据与L2相同，则无须L1将数据写回主存中，而只要L2把自己的块的内容写回即可。但还是要将该块的状态标记为非法态（I）。
- ✚ L2唤醒总线主设备，由它完成读操作。

## 目标

- 提高CPU访问存储器系统的平均速度

## 策略

- 利用一容量较小（降低成本）的高速缓冲存储器

## 组织方式

- 全相联、直接映射、组相联

## 包含性保证

- cache中的块和主存中的块进行映射

## 一致性保证

- 写回主存策略

## 提高命中率

- 容量

- 关联方式

- 块替换算法

## ❖ 局部性原理:

- ❖ 任何时候，程序需要访问的只是相对较小的一些地址空间。

- ◆ 时间局部性

- ◆ 空间局部性

## ❖ 三类主要的Cache缺失原因:

- ❖ 必然缺失: 如: 第一次装入
- ❖ 冲突缺失: 增大Cache容量、改进组织方式  
避免不断的块冲突
- ❖ 容量缺失: 增大Cache容量

## ❖ Cache设计

- ❖ 总容量、块大小、组织方式
- ❖ 替换算法
- ❖ 写策略 (命中时): 写直达、拖后写

- ❖ 写策略 (不命中时): 是否装入到Cache?

# 设计 Cache





## 有关方案

- cache 容量
- 块大小
- 组织方式
- 替换算法
- 写策略

## 方案优化

- 根据用途选择
  - 海量数据处理
  - 指令数据平衡
- 根据成本优化

## 简单化常常就是优化



# 阅读和思考



## 大实验检查验收安排

- 时间:
- 本周四\五, 下午1:30~4:30
- 地点:东主楼9-422

## 阅读

- 教材相关章节
- 预习虚拟存储器

## 思考

- Cache命中率和哪些因素有关? 如何提高Cache的命中率?
- Cache写有许多策略, 试进行比较。